The Compliance Blueprint

# NormaBot: Tu asistente de cumplimiento normativo en IA

Consulta normativa, clasifica riesgo y genera checklists de cumplimiento en segundos.

Trabajo Final de Máster · Bootcamp IA IV · KeepCoding · Equipo: Daniel Ocando, Natalia Garea, Ruben Cerezo, Maria Eugenia Alvarez.

NotebookLM

# El EU AI Act ya es ley.
# El reloj está corriendo.

| | |
|---|---|
| **La Ley** | Entró en vigor en agosto 2024. Cumplimiento obligatorio a partir de agosto 2026.<br>24 meses para el cumplimiento obligatorio en toda la UE. |
| **El Problema** | Normativa densa, altamente técnica y fragmentada (EU AI Act, LOPD, AESIA).<br>Más de 40.000 empresas en España usan IA. |
| **El Riesgo** | Multas de hasta 35M€ o el 7% de la facturación global.<br>Imposibilidad de comercializar productos. |
| **La Brecha** | Los equipos de producto no son expertos legales, y los equipos legales no entienden la arquitectura ML. |

NotebookLM

# La Solución: Un auditor IA integrado en tu flujo de trabajo

**1. Entrada del Usuario & Búsqueda**

Sistema de IA para análisis + Búsqueda semántica

**2. Clasificación de Riesgo**

Evaluador ML determina nivel de riesgo

**3. Generación de Checklist & Cumplimiento**

Generación de obligaciones legales claras

## Consulta Legal Rápida

Búsqueda semántica sobre corpus legal real (BOE, EU AI Act, AESIA, LOPD).

## Clasificación de Riesgo

Evaluador ML que determina el nivel de riesgo del sistema de IA del usuario.

## Checklist de Cumplimiento

Generación determinista de obligaciones legales claras y accionables.

NotebookLM

# Inteligencia Orquestada: Arquitectura Agentic RAG

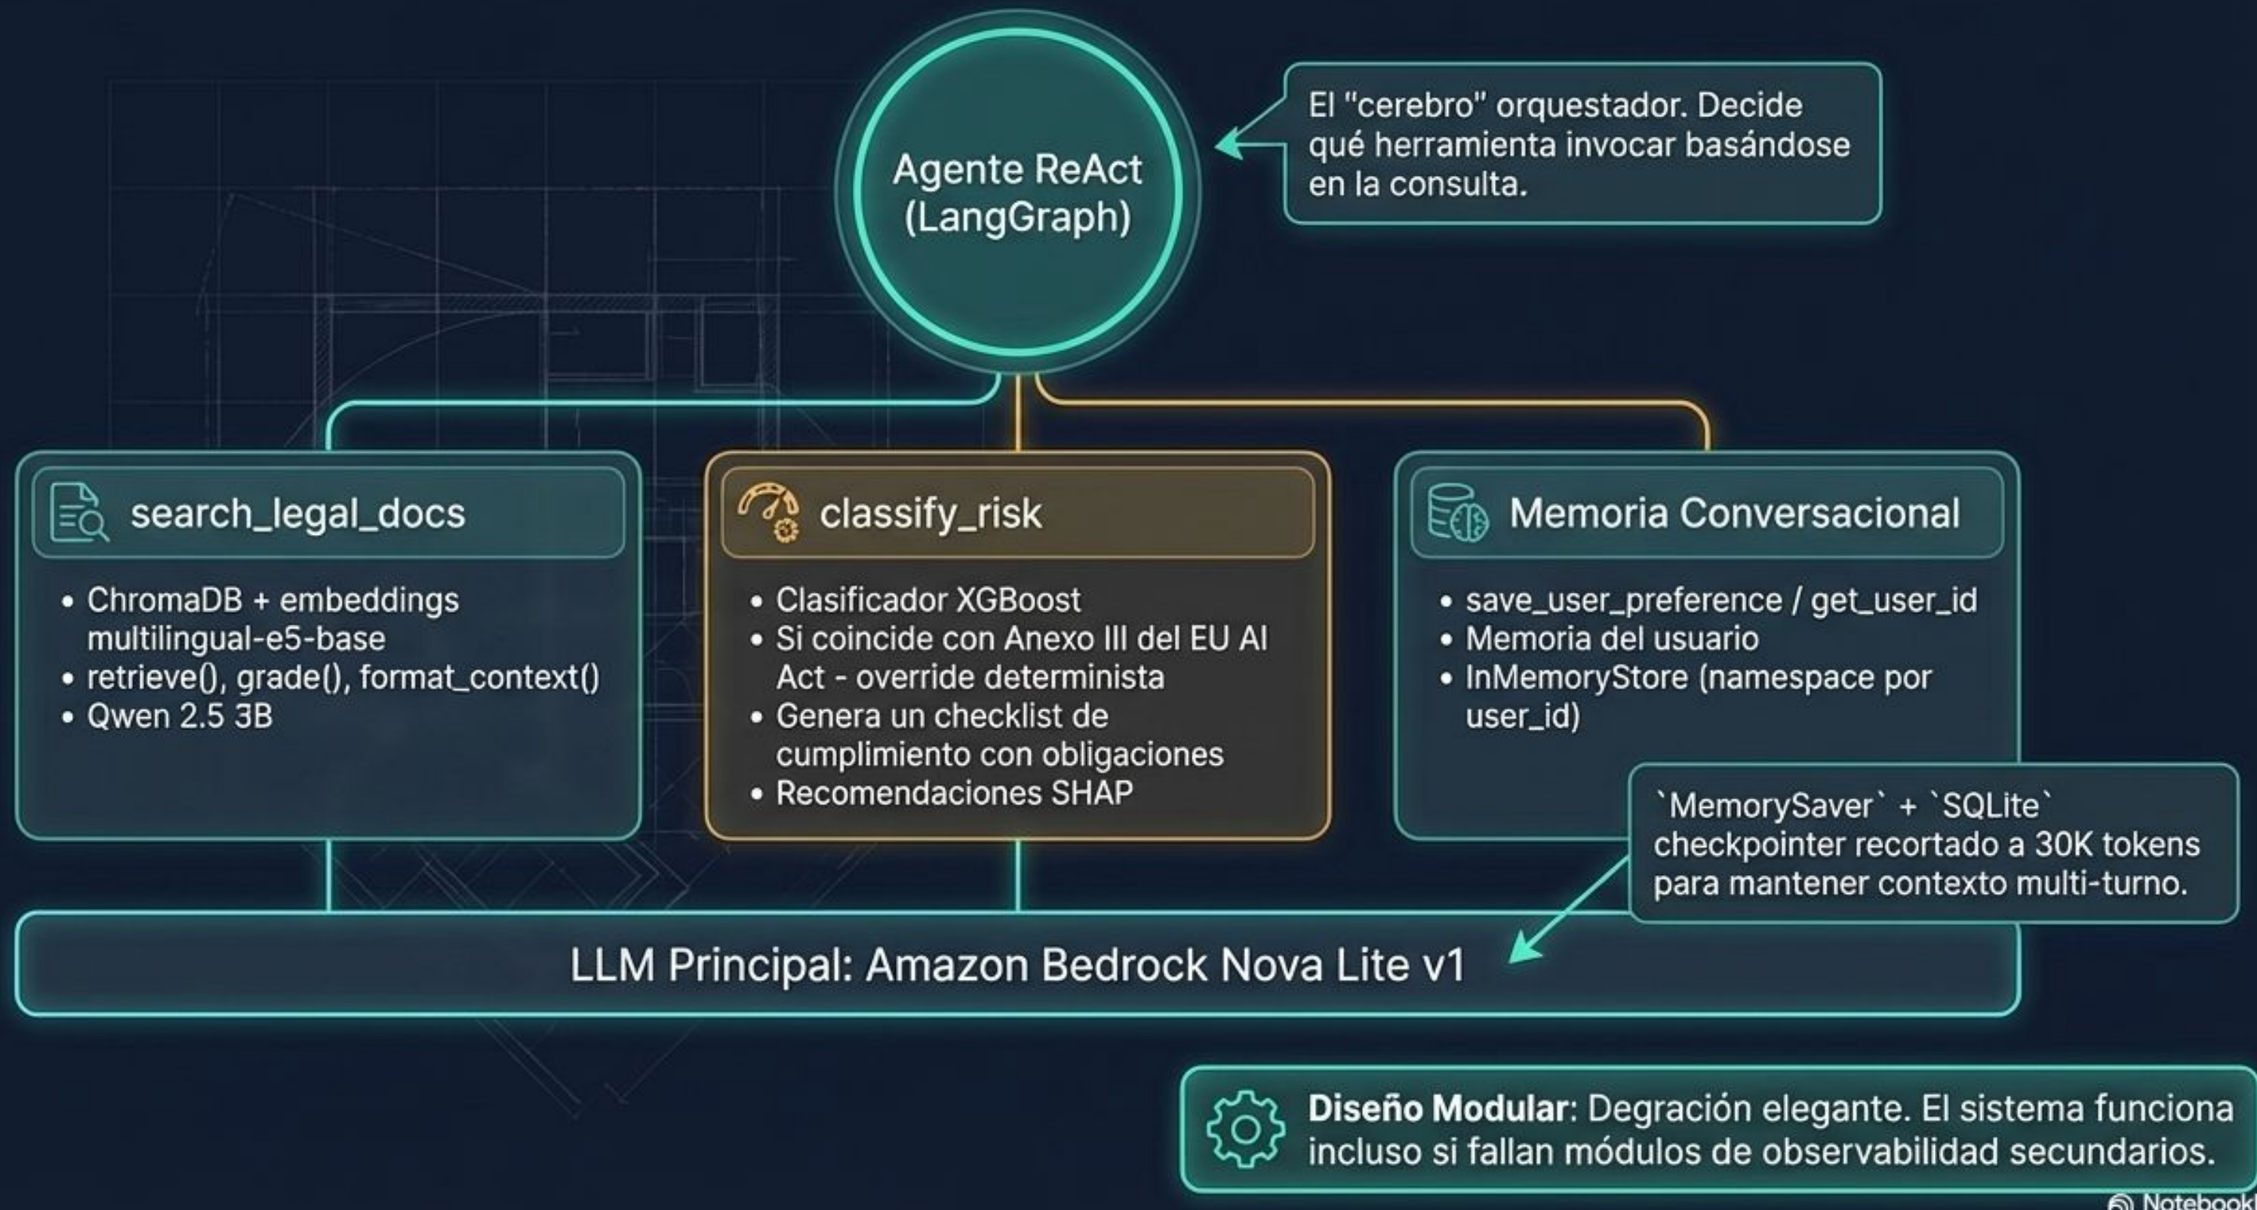


NotebookLM

# Pipeline de Ingesta de Datos: De Fuentes Legales a ChromaDB

### 1. Fuentes Legales

Colección de documentos regulatorios clave y leyes relevantes.

### 2. Ingesta

Recolección, preprocesamiento y limpieza de los textos legales.

### 3. Indexación Embedding

Conversión de texto a vectores utilizando modelos multilingües-e5-base.

### 4. Creación de ChromaDB

Almacenamiento de embeddings en una base de datos vectorial optimizada para búsqueda semántica rápida y precisa.

El proceso asegura una base de conocimientos actualizada y precisa para el sistema NormaBot.

NotebookLM

# Tool 1: RAG Correctivo y el 'Side-Channel' de Citas Seguras

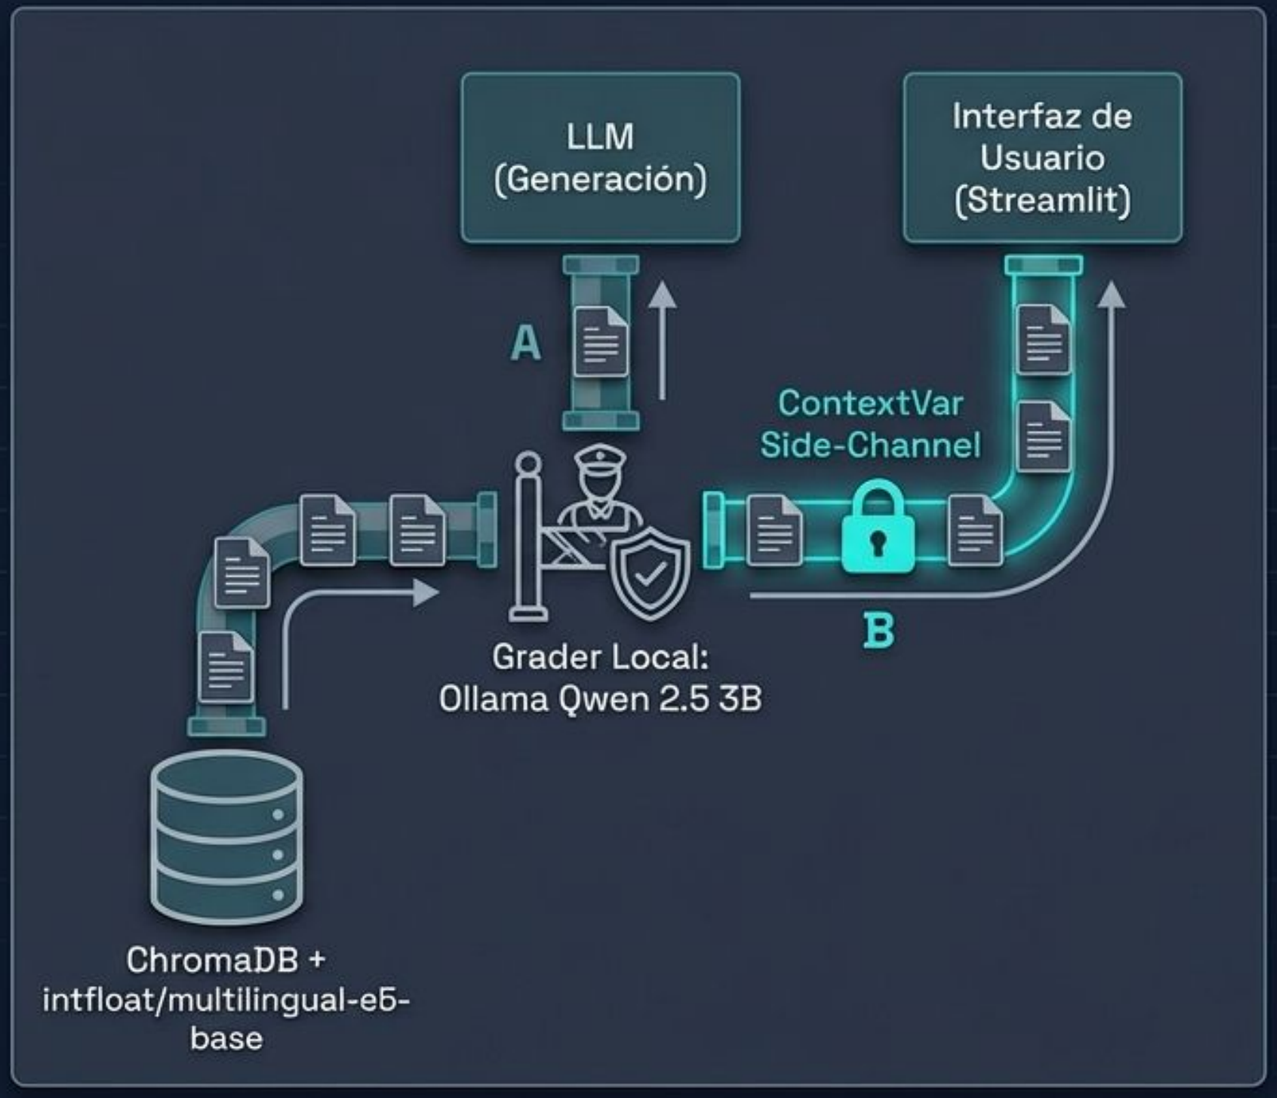


## Retriever

Prioriza coincidencia exacta -> fuente -> similitud semántica.

## Grader Local

Actúa como filtro de relevancia. Decisión técnica: modelo local para evitar latencia de red y costes de API en tareas de clasificación binaria.

## Innovación - El Side-Channel

Uso de `ContextVar` para transportar citas legales. El LLM no reformula las citas. Se inyectan directamente en la interfaz.

**Resultado: 0% alucinaciones en referencias legales.**

NotebookLM

# Tool 2: Machine Learning vs. Determinismo Legal

## El Clasificador ML

XGBoost entrenado con TF-IDF + SVD(100) + 7 features manuales (107 total). Alcanza un F1-macro de 0.88 utilizando `class_weight="balanced`` y `StratifiedKFold`. Usa SHAP para explicabilidad.

## El Override Determinista

Si el sistema detecta patrones del Anexo III o Art. 5 (ej. reconocimiento facial público), se impone el nivel de riesgo legalmente estipulado, ignorando la predicción ML.

*En derecho, la exactitud normativa prevalece sobre la probabilidad algorítmica.*

NotebookLM

# Evaluación ML: Precisión y Transparencia

## Panel de Métricas

| | |
|---|---|
| 1 | **F1-Macro (0.88)**<br>Métrica principal elegida para evitar el sesgo de la clase mayoritaria en un dataset legal desbalanceado. |
| 2 | **Evolución de Datos**<br>El paso de un dataset puramente sintético a uno fusionado (real + sintético) redujo el overfitting inicial. |

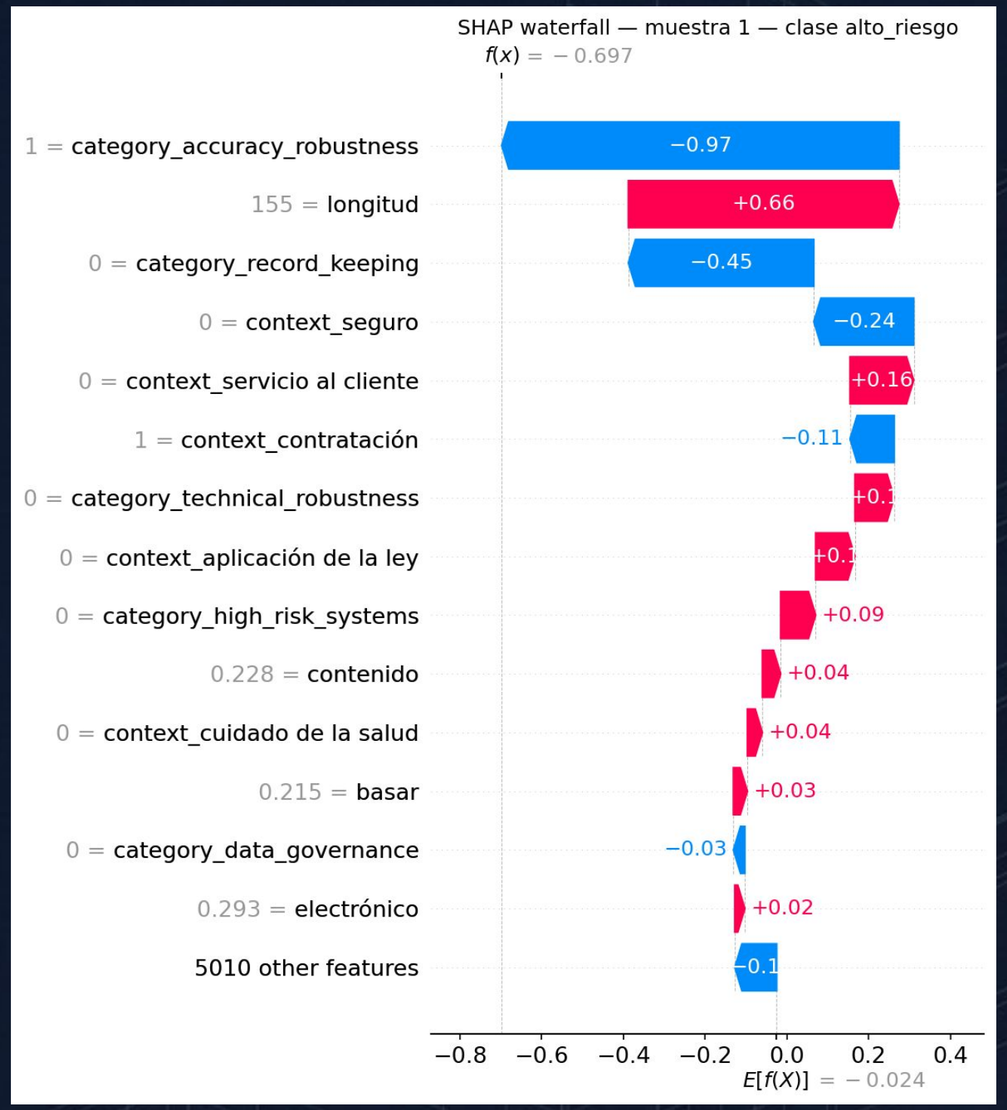


NotebookLM

# NormaBot en Producción: Flujo End-to-End

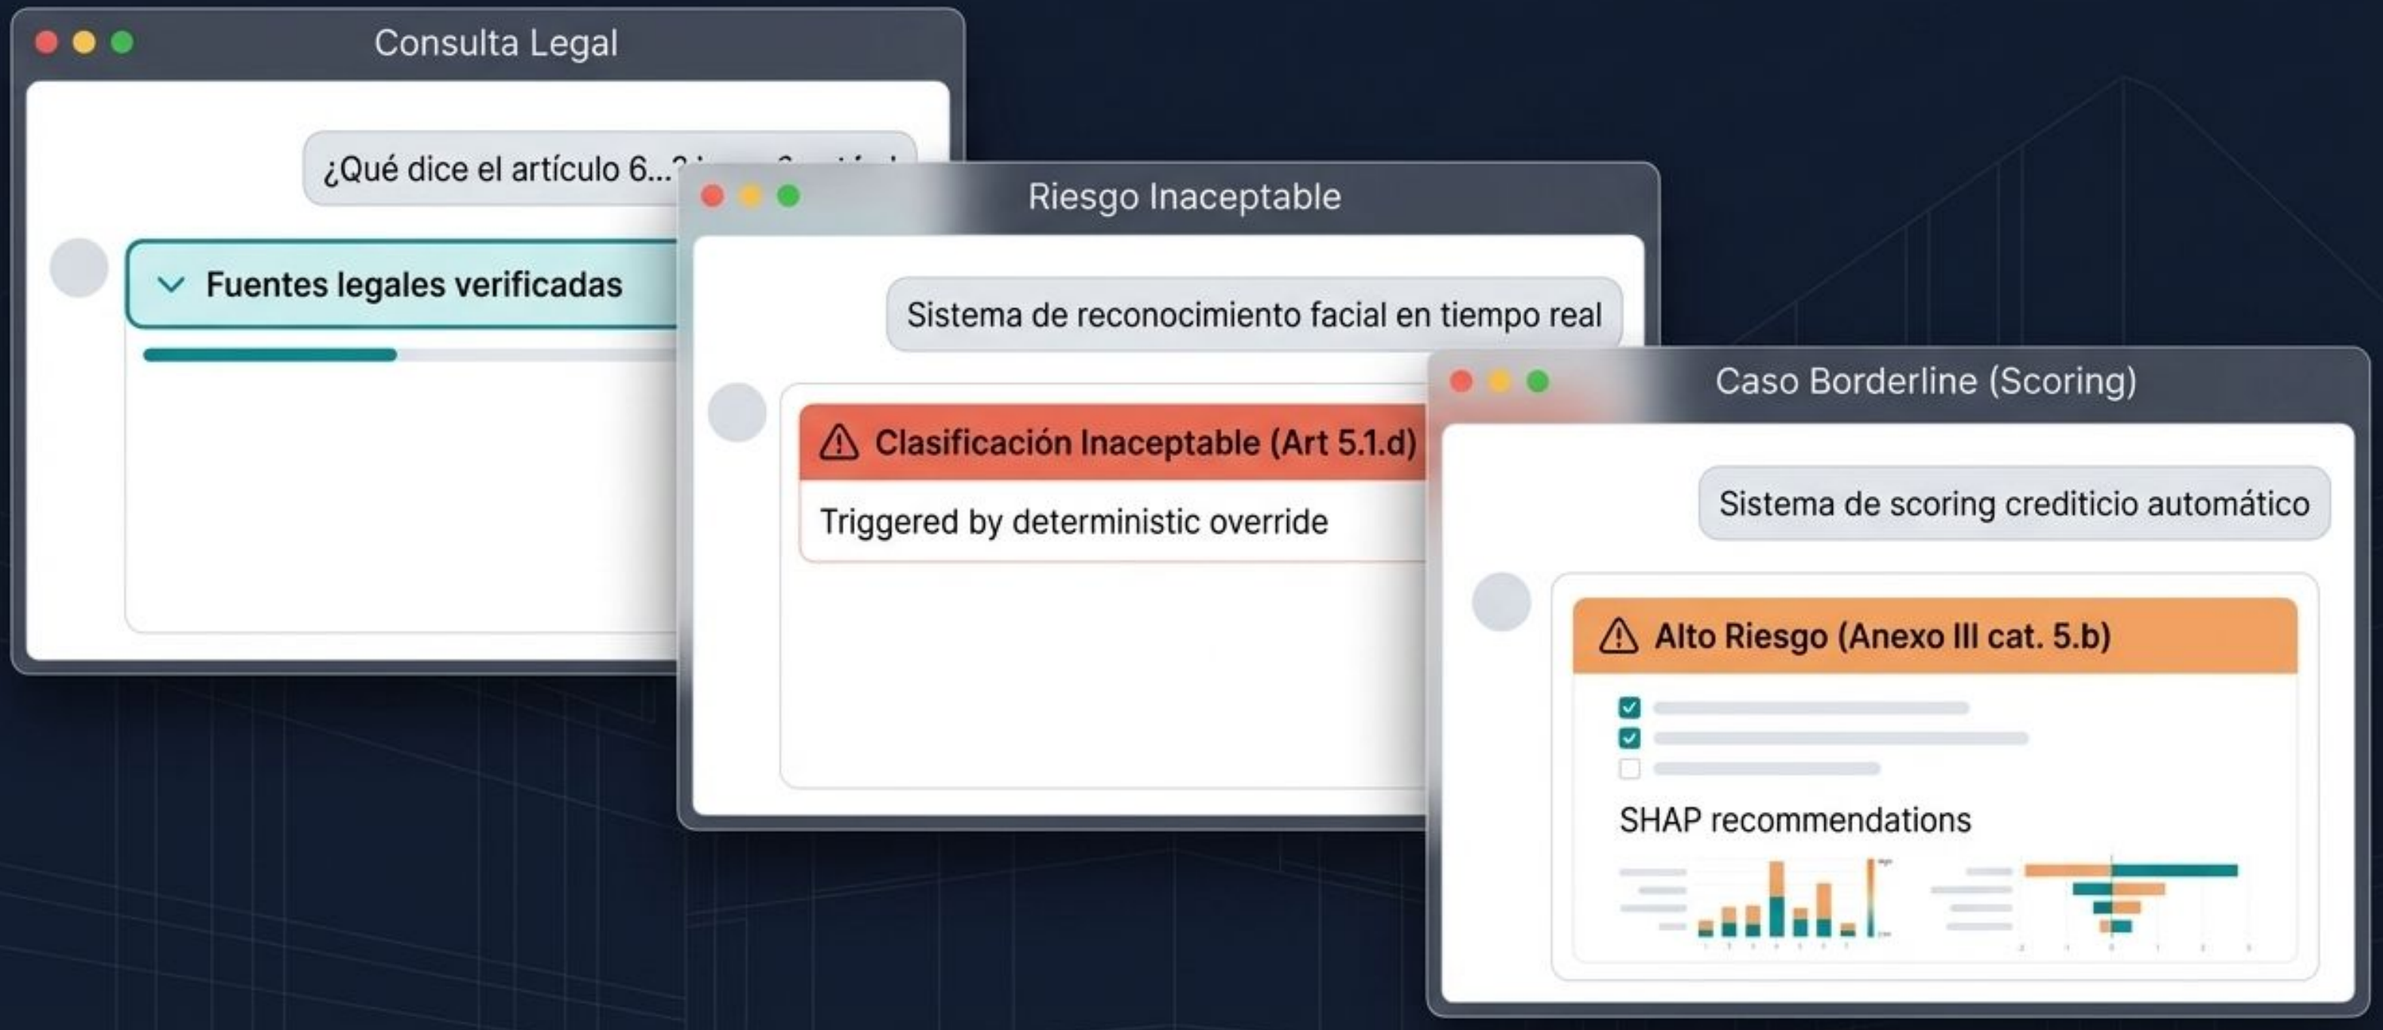


NotebookLM

# Evaluación RAGAS: Diagnóstico y Realidad

| Métrica | Expectativa vs. Realidad | Lección MLOps |
|---|---|---|
| **Faithfulness (Fidelidad)** | **Expectativa:** KPI >= 0.80.<br>**Realidad:** El LLM evaluador (Nova Lite) falló al generar el formato JSON requerido por RAGAS (`OutputParserException`), resultando en una mayoría de NaNs (64% descartados). | Desacoplar siempre el LLM de producción del LLM evaluador (ej. usar GPT-4o-mini para evaluación estructurada). |
| **Context Recall / Precision** | **Expectativa:** El grader local filtra perfectamente el ruido.<br>**Realidad:** Qwen 2.5 3B fue demasiado estricto, descartando el 50% de documentos válidos y provocando fallbacks, lo que hundió el recall (0.44). | Un bug de threshold (calibración de similitud L2) puede tumbar el pipeline. Se implementó un 'fallback por score' de emergencia. |

NotebookLM

# MLOps e Infraestructura: Diseñado para Producción

### Capa de Datos
DVC + AWS S3 (Versionamiento del corpus).

### Capa de Cómputo (EC2 + Docker)
Instancia `g4dn.xlarge` (GPU T4 para modelo local Ollama) + `t3.large` (Streamlit/UI). Containerización **multi-stage. Despliegue con Terraform y Ansible.**

### Capa de CI/CD
5 workflows de GitHub Actions (Linting, Tests, Eval, Deploy). 46 tests automatizados.

### Capa de Observabilidad
MLflow (Experimentos) + Langfuse (Trazas). Diseñado con Graceful Degradation (el sistema no se cae sl Langfuse falla).

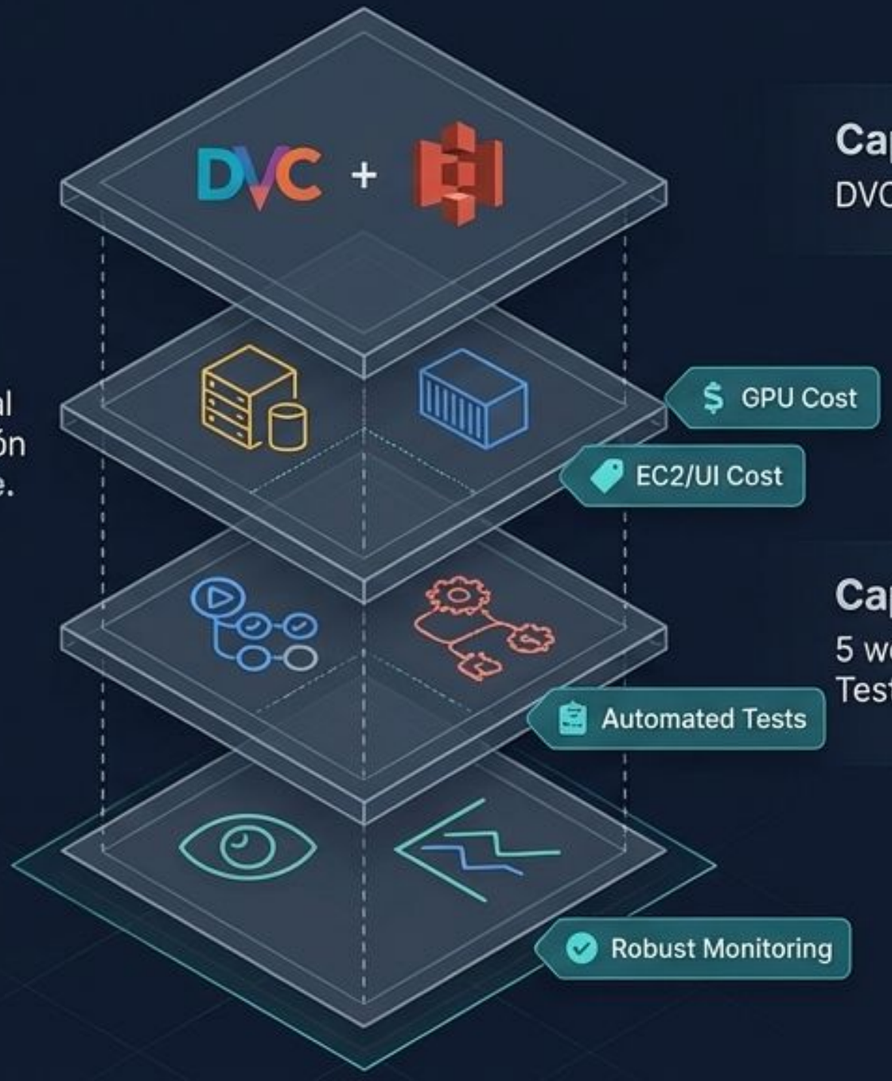


### Capa de CI/CD
5 workflows de GitHub Actions (Linting, Tests, Eval, Deploy). automatizados.

NotebookLM

# Costes y escalabilidad

## Desglose de Costes Mensuales

| Concepto | Coste/mes |
|---|---|
| NormaBot (g4dn.xlarge, GPU) | ~$384 |
| MLflow (t3.small) | ~$15 |
| EBS NormaBot (30GB + 8GB root) | ~$3 |
| EBS MLFlow (10GB + 8GB root) | ~$1.5 |
| S3 + transferencia | <$2 |
| Bedrock Nova Lite (~$0.0003/query) | Variable |
| Langfuse Cloud (observabilidad) | $0 – free tier |
| **Total fijo** | **~$406/mes** |

NotebookLM

# Retrospectiva: Lo que nos enseñó la ingeniería real

## Datos Sintéticos

*El espejismo de la perfección.*

Los primeros datasets sintéticos dieron métricas de ~95%, ocultando la complejidad del lenguaje legal real. Mezclar datos orgánicos fue doloroso pero necesario.

## El Eslabón Frágil (RAG)

*El evaluador evalúa al evaluador.*

Descubrimos que la calidad del RAG dependía enteramente del 'Grader'. Un grader estricto genera respuestas en blanco y latencias de 4 minutos.

## El Valor de la Observabilidad

*Aislar vs. Integrar.*

Módulos que funcionaban en aislamiento fallaron al integrarse. Langfuse fue vital: nos permitió cazar un bug crítico de 'doble llamada al LLM' causado por ejecución paralela.

NotebookLM

# Claude Code: Agente Colaborativo del Equipo (.claude/)

Configuramos Claude Code como un miembro más del equipo, con conocimiento del proyecto.

## 1. Skills (Comandos /slash)

- **/tutor**: Orquestador principal
- **/diagnostico**: Clasifica estado de módulos
- **/planificar:** Crea sprint plans
- **/revisar**: Code review con contexto

Claude Code

## 2. Agentes y Hooks (Automatización)

- **Agentes Especializados (Read-only):** Escaneo rápido y code reviews.
- **Hooks (Eventos):** SessionStart (contexto) y PostToolUse (tests)

## 3. Arquitectura y Flujo

- Flujo de Trabajo: Inicio → /tutor → /diagnostico → /planificar → Code → /revisar → Entrega

**Beneficios Clave:** Compartido vía Git | Consistencia de Contexto | Agentes Seguros

NotebookLM

# CodeRabbit: Automated PR Reviewer

## Qué es y Configuración Clave

**GitHub App** para revisión automática en español.
Configurado con **.coderabbit.yaml**.

```yaml
path_instructions:
  - path: "**/*.py"
    instructions: >
      Este es un MVP académico. NO reportes estilo, linting, formato, etc.
      Céntrate SOLO en:
      1. Fallos de concepto o lógica (pipeline RAG, LangGraph)
      2. Vulnerabilidades de seguridad
      3. Problemas de rendimiento (N+1, memoria, bloqueos)
      4. Errores de runtime
      5. Problemas de concurrencia
  - path: "**/*.{yaml,yml}"
    instructions: >
      Solo errores de runtime. Ignorar formato y estilo.
  - path: "Dockerfile"
    instructions: >
      Revisar solo seguridad y errores de build/ejecución. Ignorar cosmética.
```

## Flujo y Valor Añadido

**Datos Reales:** PR #121 (30 comentarios); PR #133 (1 link roto).

**Valor para el Equipo (4 personas):**

- Reduce carga de review.
- Consistencia en criterios.
- Educativo (seguridad/buenas prácticas).
- Zero config operativo.

NotebookLM

# Próximos Pasos: Mejorando NormaBot

- Auto-Actualización Normativa
- Fine-Tuning del Grader
- Utilización de Queries de Usuarios
- Cambiar el Modelo Evaluador de RAGAS

NotebookLM

# Gracias. ¿Preguntas?

Daniel Ocando | Natalia Garea | Ruben Cerezo | Maria Eugenia Alvarez

NotebookLM